

LLM 모델 비교·선정 결과 보고서

회의록 요약 및 후속 조치(Action Items) 추출 성능 비교를 중심으로

프로젝트명	Antigravity V3 릴리즈 점검	작성일자	2026년 7월 6일
작성자	프로젝트 관리자 (PM)	대상 모델	제미나이 Pro, GPT, 그록

1. 비교 평가 개요

신규 모바일 앱 'Antigravity V3'의 릴리즈 전 최종 점검 회의록(대화체 녹취록)을 바탕으로, 부서 간의 복잡한 조율 사항, 누락된 정책적 의사결정, 담당자별 구체적 Action Items를 누락이나 환각 없이 가장 체계적이고 구조화된 포맷으로 요약해내는 최적의 대규모 언어 모델(LLM)을 선정하고자 비교 분석을 진행하였습니다.

2. 평가 방법론 및 테스트 환경

각 AI 모델에 완전히 동일한 테스트 프롬프트 및 원문 대화 데이터(2주 뒤 공식 런칭 예정인 'Antigravity V3'의 QA, 일정 충돌, 구독 플랜 포인트 정책, 카카오톡 URL 오류 논의 포함)를 주입하고 출력 결과를 정량적/정성적 지표로 교차 검증하였습니다.

테스트 핵심 제약 사항

- 핵심 요약 (3줄 이내), 부서별 Action Items (담당자, 과업, 기한 명시), 리스크/미확정 사안 도출
- 보안 준수: 참가자 실명을 '역할명(예: 개발팀 파트장)'으로 100% 마스킹할 것
- 원문에 근거가 없는 추측성 정보나 허구의 일정(환각) 생성 금지

3. 모델별 정량 평가 비교표

평가 기준 (5점 만점)	AI ① 제미나이 Pro (유료)	AI ② GPT (무료)	AI ③ 그록 (무료)
내용의 정확성 (사실 기반)	5 / 5	4 / 5	4 / 5
한국어 표현 및 자연스러움	4 / 5	5 / 5	4 / 5
지시 형식(포맷) 준수율	5 / 5	4 / 5	3 / 5
긴 컨텍스트 기억/유지력	5 / 5	4 / 5	3 / 5
평균 점수	4.75 / 5.0	4.25 / 5.0	3.50 / 5.0

4. 모델별 세부 평가 결과

1) 제미나이 Pro 최종 선정

3가지 출력 목차 및 제약 조건을 완벽히 준수함. 웰컴 포인트 지급 규정 누락을 '미확정 사안'으로 정확하게 짚어내었으며, 인물의 실명을 완벽하게 필터링하여 보안 마스킹 기준을 100% 통과함. API 및 시스템 지침 강제성이 매우 뛰어나 고난도 다중 제약 비즈니스 환경에 가장 적합한 모델로 판단됨.

2) GPT

한국어 문장의 유연성과 개조식의 가독성은 3개 모델 중 가장 자연스러움. 그러나 실명을 완벽하게 필터링하지 못하고 일부 대화 요약 부분에서 '김마케 팀장'이라는 실명을 그대로 노출하는 포매팅 실수가 발견되어 감점 처리됨.

3) 그록 (Grok)

전체적인 회의 요약의 맥락은 무난하게 파악하였으나, 구체적인 기한 조건('오늘 퇴근 전', '3시 반' 등)을 구체적이고 일목요연한 개조식 포맷 안에 녹여내지 못하고 단순 서술형으로 뭉뚱그려 출력하여 비즈니스 가독성이 떨어짐.

최종 의사결정 요약:

다중 제약 조건(실명 마스킹, 3단 구조화 포맷, 명사형 종결어미)이 복잡하게 얹힌 프롬프트 지시 사항을 단 하나의 누락 없이 안정적으로 완수한 **제미나이 Pro**를 'Antigravity V3' 프로젝트 회의록 요약 전담 모델로 최종 선정함.